

FILIÈRE GÉNIE INFORMATIQUE & INTELLIGENCE ARTIFICIELLE

DÉVELOPPEMENT D'UN SYSTÈME DE DÉTECTION D'INTRUSIONS RÉSEAU (NIDS) BASÉ SUR LE DEEP LEARNING

PRESENTATION DU PROJET DE FIN D'ÉTUDES

PRÉSENTÉ PAR :

Mathieu AKAKPO-DJAKPATA

Élève Ingénieur en Génie Informatique & Intelligence Artificielle

SOUS LA DIRECTION DE :

Mme Saida HAIDRAR (Encadrante HESTIM)

M. Hamza MOUNCIF (Maître de Stage - 3D Smart Factory)

ANNÉE UNIVERSITAIRE : 2025-2026


Plan de la Présentation



Introduction & Contexte

I

Présentation de l'entreprise, contexte cyber, limites de l'existant, méthodologie & planning.



Cartographie Technologique

IV

Sonde active NFStream, ingestion asynchrone Amazon SQS & stockage persistant DynamoDB.



Modélisation Deep Learning

II

Dataset CICIDS2017, variables caractéristiques, benchmark de 11 architectures & modèle champion.



Supervision & Validation

V

Validation expérimentale sous scénarios d'attaques réelles & supervision via React SOC UI.



Architecture AWS

III

Conception du CyberRange Cloud, provisionnement Terraform et configuration Ansible.



Bilan & Perspectives

VI

Bilan du PFE, ouverture sur l'IA Explicable (XAI) & perspectives R&D.

i CONTEXTE & ENJEUX

Introduction Générale

■ Contexte Cyber

01

CLOUD & IOT

TRANSVERSE

- ♦ **Transformation Numérique** : Hybridation Cloud/IoT multipliant la surface d'exposition.
- ♦ **Menaces Furtives** : Scans distribués, attaques DDoS complexes et intrusions APT.
- ♦ **Surveillance Passive** : Rôle clé du NIDS pour une écoute réseau globale et non intrusive.

■ Limites du SOC

02

ZÉRO-DAY

FAUX POSITIFS

TLS 1.3

- ♦ **Impuissance des Signatures** : Inefficaces face aux menaces Zero-Day inédites.
- ♦ **Fatigue des Alertes** : Seuils d'experts statiques inondant le SOC de faux positifs.
- ♦ **Chiffrement Global** : Tunnel TLS 1.3 empêchant l'inspection de contenu (DPI).

 STRUCTURE D'ACCUEIL

Présentation de l'Entreprise d'Accueil

▪ 3D Smart Factory (CSIT) -- Mohammedia

INCUBATEUR RECHERCHE & DÉVELOPPEMENT

MAROC

CYBER & IA

Structure mixte accompagnant l'innovation technologique et industrielle de la Recherche & Développement jusqu'à la mise en production.

Encouragement

01

Création d'un climat de confiance et de motivation pour stimuler l'innovation technologique.

Encadrement

02

Accompagnement technique rapproché, méthodes agiles et support au prototypage rapide.

Financement

03

Dimensionnement financier, structuration réglementaire et aide à la levée de fonds.

 CADRAGE DU PROJET

Cadrage & Périmètre du Projet

🚀 **TRANSITION MAJEURE** : Dépasser le simple benchmark théorique hors-ligne pour bâtir un pipeline de détection d'intrusions passif, continu et opérationnel sur AWS.

 Dans le Périmètre

IN

SMOTE PYTORCH NFSTREAM IAC AWS

- ♦ **Équilibrage SMOTE** : Traitement du déséquilibre de classe (99% sain).
- ♦ **Modélisation DL** : Entraînement et benchmark de 11 réseaux profonds.
- ♦ **Sonde Active** : Capture passive et extraction continue avec NFStream.
- ♦ **Automatisation** : Déploiement CyberRange via Terraform/Ansible.
- ♦ **SOC Live** : Dashboard React avec résolution des tags d'instances EC2.

 Hors Périmètre

OUT

SIEM / EDR SOAR LOGS SYS

- ♦ **Remplacement SIEM/EDR** : Pas de substitution des solutions en place.
- ♦ **Mitigation Active** : Pas de blocage automatique des flux (SOAR).
- ♦ **Logs Système** : Pas de corrélation de logs applicatifs ou IAM.
- ♦ **Coûts Multi-Régions** : Optimisation financière multi-VPC non traitée.

 ANALYSE DES SPÉCIFICATIONS

Besoins Fonctionnels & Non Fonctionnels

 Besoins Fonctionnels

- A**  **Capture & Ingestion**
Capture passive sans impact sur la production, agrégation en flux et extraction des 77 caractéristiques normalisées.
- B**  **Prétraitement & Inférence**
Prétraitement cohérent (imputation, IQR, normalisation), inférence temps réel (15 classes d'attaques) et seuil de confiance ajustable.
- C**  **Alerting & Supervision**
Génération d'alertes asynchrones enrichies, diffusion temps réel vers le SOC et tableau de bord interactif (historique, stats).
- D**  **Validation & Reproductibilité**
Validation globale par scénarios d'attaque reproductibles et déploiement automatisé de l'architecture par scripts.

 Besoins Non Fonctionnels **Latence & Temps Réel**

Faible latence de traitement de bout-en-bout (objectif < 2 s) pour l'alerte SOC immédiate.

 Scalabilité

Capacité à absorber des volumes de trafic élevés et des pics d'alertes sans goulot d'étranglement.

 Disponibilité

Architecture à base de composants découplés asynchrones garantissant une reprise d'activité sans perte.

 Sécurité

Capture hors bande (écoute passive) sans impact de production, et respect du principe du moindre privilège.

 VEILLE TECHNIQUE

Limites des Approches Traditionnelles (Signatures)

▪ Zero-Days

01

SNORT / SURICATA

Les moteurs à signatures recherchent des empreintes connues.

✖ Si l'attaque est inédite, elle passe sans alerter le SOC.

▪ Chiffrement

02

TLS 1.3

OBFUSCATION

L'obfuscation déjoue les signatures textuelles.

✖ TLS 1.3 empêche l'inspection profonde (DPI) sans SSL Decrypt lourd.

▪ Surcharges

03

10 GBPS+

PACKET DROPS

L'analyse de motifs intensifs sature les CPU de filtrage.

✖ Pertes massives de paquets sur haut débit, créant des angles morts.

📅 ORGANISATION DE PROJET

Méthodologie de Travail & Planning



Méthodologie Itérative (Agile SCRUM)

Sprints de 2 à 4 semaines avec livrables validés en continu.




Utilité Majeure

Anti-effet tunnel, validation rapide des baselines IA & conformité aux contraintes de production.



Diagramme de Gantt du Projet (20 Semaines)



 RÉVOLUTION IA

L'avènement du Deep Learning pour le NIDS

▪ Auto-Apprentissage

01

SELF-FEATURE DEEP NET

- ♦ **Fin du Manuel** : Plus besoin de Feature Engineering manuel et fastidieux.
- ♦ **Représentations** : Extraction automatique des patterns abstraits et non-linéaires profonds.

▪ Généralisation

02

ZERO-DAY PROTECTION PROBABILISTE

- ♦ **Comportemental** : Modélisation fine du trafic normal vs malveillant.
- ♦ **Adaptabilité** : Détection de variantes d'attaques et de menaces inconnues.

▪ Anti-Chiffrement

03

TLS 1.3 STATISTIQUES

- ♦ **Zéro Déchiffrement** : S'affranchit de l'inspection de contenu du payload.
- ♦ **Métadonnées** : Focus sur les durées, volumes d'octets et écarts inter-paquets.

 DONNÉES DE RÉFÉRENCE

Le Dataset de Référence : CICIDS2017



2 830 743

FLUX RÉSEAU BIDIRECTIONNELS



77

VARIABLES STATISTIQUES (FEATURES)



15

CLASSES (1 SAINE · 14 ATTAQUES)

 Taxonomie des Menaces Couvertes**Trafic Sain**


HTTP, HTTPS, FTP, SSH

**DoS / DDoS**

SYN Flood, Hulk, GoldenEye, Slowloris

**Reconnaissance**

PortScan, balayages furtifs

**Infiltrations**

BruteForce, SQLi, XSS, Heartbleed, Botnets

VARIABLES CARACTÉRISTIQUES

Variables Caractéristiques (Sélection des plus pertinentes parmi 77 Features)

Bien que l'ensemble des 77 caractéristiques soit important pour l'apprentissage global du modèle, nous présentons ici un zoom sur les variables les plus représentatives et pertinentes.

Le Quintuplet Standard (5-Tuple)

Chaque flux réseau est identifié et regroupé de façon bidirectionnelle par :

IP Source	Port Source
IP Destination	Port Destination
Protocole (TCP / UDP)	

*Note : Le **Port Destination** est une variable statistique cruciale indiquant le service ciblé (ex: 80/HTTP, 22/SSH).

Drapeaux & En-têtes TCP (Flags)

Le nombre d'occurrences et la distribution des drapeaux de signalisation réseau :

SYN	ACK	PSH
FIN	RST	URG

Permet de caractériser les comportements d'attaques comme les scans furtifs ou les inondations (ex: SYN Flood).

Les Variables Statistiques (77 Features)

Stats Réelles

Extraites par **NFStream / CICFlowMeter**. Dispersion réelle calculée sur 150k flux (Monday Dataset) :

Variables Temporelles (IAT) :

- Durée totale (Flow Duration) : **Moyenne = 16,1s | Std = 33,9s**
- Temps inter-paquets (Fwd/Bwd IAT Total) : **Std ~33s**

Variables Volumétriques (Volume & En-têtes) :

- Volume total retour (Total Length of Bwd Packets) : **Max = 655 Mo**
- Taille en-tête forward (Fwd Header Length) : **Std = 5,8 Mo**

Débits & Configuration TCP :

- Débit forward (Fwd Packets/s) : **Moyenne = 76,7k p/s | Max = 3M p/s**
- Fenêtre initiale TCP (Init_Win_bytes_forward) : **Moyenne = 14,4k octets**

PIPELINE DE DONNÉES

Pipeline de Prétraitement & Équilibrage des Données



ÉTAPE 01

Nettoyage & Imputation

NETTOYAGE NAN LABEL ENCODING

- Conversion des $\pm Inf$ en NaN et imputation par la médiane du Train Set (anti-leakage).
- Encodage Label des variables catégorielles et des 15 classes cibles.



ÉTAPE 02

Écrêtage IQR

CLIPPING IQR FACTEUR 1.5

- Calcul des bornes de confiance stables par variable : $Q1/Q3 \pm 1.5 \times IQR$.
- Écrêtage sans suppression pour préserver l'intégrité des signatures d'attaques volumétriques.



ÉTAPE 03

Normalisation

Z-SCORE SCALER

- Standardisation centré-réduite ($z = (x - \mu) / \sigma$) des 77 caractéristiques physiques.
- Sauvegarde de la moyenne et variance du Train Set pour l'inférence temps réel.



ÉTAPE 04

Équilibrage

RUS (50K) SMOTE (K=5)

- Sous-échantillonnage de la classe saine ('BENIGN') à 50k pour élaguer la redondance.
- Interpolation linéaire vectorielle locale pour rééquilibrer les classes minoritaires à 5 796.

 BENCHMARK MODÉLISATION

Les 11 Architectures de Deep Learning Testées

 Baselines Standards

01

MLP DEEP MLP

- ♦ **MLP Standard** : Classification simple de vecteurs statistiques mis à plat.
- ♦ **MLP Profond** : 5 couches cachées denses pour capter les non-linéarités.

 Modèles Spatiaux

02

CNN 1D RESNET 1D

- ♦ **CNN 1D** : Extraction de corrélations spatiales locales entre variables.
- ♦ **ResNet 1D** : Connexions résiduelles anti-disparition de gradient.

 Modèles Séquentiels

03

LSTM GRU BiLSTM

- ♦ **LSTM & GRU** : Captures récurrentes des dépendances logiques.
- ♦ **BiLSTM** : Double parcours temporel pour un contexte bidirectionnel maximal.

 Modèles à Attention

04

TCN ATTENTION MLP

- ♦ **TCN** : Convolutions causales dilatées temporelles haute vitesse.
- ♦ **Attention MLP (Champion)** : Pondération dynamique de l'importance des variables.

 PHASE DE MODÉLISATION

Processus d'Entraînement des Modèles

Pondération des Classes (Loss)

Utilisation de la **Cross-Entropy pondérée** (CrossEntropyLoss) pour pénaliser plus fortement les erreurs sur les classes minoritaires (les attaques) et compenser le fort déséquilibre du dataset.

Optimisation & Convergence

Mise à jour des poids via l'optimiseur **Adam**, combiné à un ajustement dynamique du taux d'apprentissage sur plateau (division par 2 si stagnation de la loss de validation).

Configuration du Training (Hyperparamètres Clés)

TAUX D'APPRENTISSAGE

0.001
ADAM OPTIMISEUR

Valeur initiale. Ajustement automatique via ReduceLRonPlateau (facteur 0.5, patience 3).

TAILLE DE BATCH

512
ÉCHANTILLONS

Taille de batch élevée pour stabiliser les gradients de loss pondée et accélérer l'inférence.

ÉPOQUES MAX

50
LIMITE D'ÉPOQUES

Seuil théorique de fin d'entraînement. La convergence optimale est atteinte entre 15 et 30 époques.

EARLY STOPPING

10
PATIENCE D'ARRÊT

Arrêt prématuré si la loss de validation ne diminue plus pendant 10 époques (anti-overfitting).

 ÉVALUATION EXPÉRIMENTALE

Résultats du Benchmark Quantitatif

 BENCHMARK QUANTITATIF STANDARDISÉ MENÉ SUR 11 ARCHITECTURES PYTORCH AVEC LE DATASET CICIDS2017 :

Architecture de Réseau	Exactitude (Accuracy)	F1-Score Global	Temps d'inférence (flux)	Nombre de paramètres
Attention MLP (Sélectionné)	98.28 %	98.29 %	0.42 ms	49 915
ResNet 1D	97.45 %	97.40 %	1.15 ms	215 840
CNN 1D	96.90 %	96.85 %	0.85 ms	125 500
BiLSTM	96.80 %	96.75 %	4.80 ms	350 000
MLP Standard	95.10 %	95.05 %	0.35 ms	25 000

LE MODÈLE CHAMPION

Sélection du Modèle Optimal : Attention MLP

MODÈLE SÉLECTIONNÉ : ATTENTION MLP

L'architecture surclasse tous les autres réseaux testés en alliant des performances d'exactitude exceptionnelles avec une compacité structurelle optimale pour l'inférence temps réel continue sans GPU.

Sensibilité

01

ACCURACY: 98.28% F1: 98.29%

- ♦ **Anomalies Rares** : Excellente isolation des intrusions furtives.
- ♦ **Précision** : Élimination quasi-totale des faux positifs.

Vitesse CPU

02

0.42 MS / FLUX TAILLE: 50 KO

- ♦ **Légèreté Extrême** : Modèle compact (49k paramètres) tournant sur CPU simple.
- ♦ **Zéro Lag** : Pas de goulot d'étranglement sur la sonde active.

Interprétabilité


03

POIDS D'ATTENTION XAI SOC

- ♦ **Poids d'Attention** : Pondération en direct de l'importance de chaque variable.
- ♦ **Transparence** : Permet de comprendre le déclenchement de l'alerte.

FOCUS ARCHITECTURE

Architecture Interne de l'Attention MLP



⚡ Pondération Attentionnelle

Calcul des poids d'attention α_i par Softmax. Permet au réseau de se focaliser dynamiquement sur les variables les plus discriminantes à chaque instant.

▼ Gating de Hadamard ($x \odot \alpha$)


Multiplication terme à terme qui filtre et élimine dynamiquement le bruit (les variables redondantes induites par le collecteur de flux).

🌐 Compacité & Rapidité

Seulement **50 Ko** (49,9k paramètres). Latence d'inférence de **0,42 ms** sur CPU simple, permettant une classification réseau en temps réel à très haut débit.


LE CYBERRANGE AWS

Architecture Globale du CyberRange Cloud



 CARTOGRAPHIE TECHNOLOGIQUE

Technologies & Outils par Niveau



Recherche & Développement / IA

01

PYTORCH SMOTE SKLEARN

- 🔦 **Benchmark** : 11 architectures PyTorch testées.
- 🔦 **Équilibrage** : SMOTE (imbalanced-learn).
- 🔦 **Analyse** : Pandas, NumPy & Sklearn.

Recherche & Développement algorithmique



Infra & IaC

02

TERRAFORM ANSIBLE AWS EC2

- 🔦 **IaC AWS** : Provisionnement Terraform (VPC, subnets).
- 🔦 **Conf** : Provisioning des instances via Ansible playbook.

Automatisation



Sonde & Capt

03

NFSTREAM VXLAN TRAFFIC MIRR

- 🔦 **Écoute** : VPC Traffic Mirroring passif sans agent.
- 🔦 **VXLAN** : Tunneling natif Linux Kernel port 4789.
- 🔦 **Sonde** : Démon d'extraction Python (NFStream).

Flux réseau passif



Ingestion Cloud

04

AWS SQS LAMBDA DYNAMODB

- 🔦 **SQS** : File d'attente élastique anti-surcharge.
- 🔦 **Lambda** : Traitement asynchrone des alertes.
- 🔦 **NoSQL** : Stockage persistant DynamoDB.

Élasticité & Sécurité



SOC & API

05

FASTAPI REACTJS WS LIVE

- 🔦 **API Backend** : FastAPI asynchrone (Boto3).
- 🔦 **WebSockets** : Push temps réel vers le client.
- 🔦 **Frontend** : React avec Chart.js dynamique.

Visualisation live

Dashboard du SOC

AI-NIDS.SOC

Monitoring Live

Historique SQS

Analyse Menaces

Configuration

Tableau de Bord SOC - Surveillance Directe

Surveillance active des flux réseau via Traffic Mirroring



ONLINE



FLUX RÉSEAU ANALYSÉS

179

ATTAQUES CRITIQUES

179

LATENCE D'INFÉRENCE

1.88 ms

NIVEAU DE MENACE

CRITIQUE

Cibles du Cyberrange AWS

Victim-Web

Web Service

• SÉCURISÉ

apache2 (HTTP) PHP

Alertes SQS: 17

Victim-DB

Database Service

• SÉCURISÉ

mariadb (SQL) redis

Alertes SQS: 25

Victim-File

File Service

• SÉCURISÉ

samba (SMB) vsftpd (FTP)

Alertes SQS: 10

Flux d'Alertes en Direct

Rechercher IP/Attaque...

Toutes cibles

Plus Récents :

DE jj/mm/aaaa A jj/mm/aaaa

CRITIQUE

DoS_GoldenEye 100.0% conf.

20.193.153.215 → Victim-Web (apache2)

28/05/2026 15:57:46

MOYENNE

PortScan 100.0% conf.

Victim-DB → 3.253.221.237 (Unknown)

28/05/2026 15:54:53

MOYENNE

PortScan 100.0% conf.

Victim-Web → 3.253.217.42 (Unknown)

28/05/2026 15:51:58

Répartition des Attaques



DoS_GoldenEye PortScan Heartbleed

Cibles Visées

 RÉSULTATS RÉELS

Validation Expérimentale & Attaques

Attaques Simulées

SIM

KALI LINUX

SCAPY VM

DOS & SCANS

- ♦ **SYN Flood DDoS** : Inondation volumétrique TCP SYN visant à saturer la cible.
- ♦ **PortScan** : Scans de ports distribués et lents.
- ♦ **ICMP Flood** : Inondation de paquets de contrôle réseau.
- ♦ **Non-Régression** : Trafic sain intensif injecté en parallèle.

 **VRAIS POSITIFS (DÉTECTÉS)**

Précision du modèle en conditions réelles

100 % **LATENCE GLOBALE**

Délai de traitement bout-en-bout

< 2 s **IMPACT CPU**

Charge sur les serveurs cibles

0.00 %

 BILAN DU PROJET

Conclusion & Perspectives

■ Bilan du Projet PFE

OUT

CONCRÉTISATION RECHERCHE & DÉVELOPPEMENT

INFÉRENCE GPU

- ♦ **DL Théorique vers Cloud** : Déploiement d'un pipeline passif de bout-en-bout résilient sur AWS.
- ♦ **Attention MLP Retenu** : Inférence rapide (0,42ms) et modèle compact de 50 Ko.
- ♦ **Ingestion Découplée** : VPC Mirroring, SQS, DynamoDB et FastAPI WebSockets.

■ Perspectives Recherche & Développement

NEXT

MLOPS

XAI SOC

SOAR AWS

- ♦ **MLOps Continu** : Réentraînement automatique sur détection de dérives de données (data drift).
- ♦ **IA Explicable (XAI)** : Intégration SHAP/LIME.
- ♦ **Réponse Active (SOAR)** : Quarantaine via modification d'AWS Security Groups.



FIN DE LA PRÉSENTATION

Merci pour votre attention



PLACE AUX QUESTIONS

J'ATTENDS VOS QUESTIONS AVEC INTÉRÊT.